

[文章标题]

NetLLM: Adapting Large Language Models for Networking

—SIGCOMM '24

[研究背景与动机]

近年来，随着机器学习在各领域的广泛应用，网络系统中也逐渐兴起使用机器学习进行优化网络的研究，这一趋势并未实际减轻网络工程的工作负担。相反，由于这种工程设计在不同任务之间是不可共享的，以至于开发者在不同任务之间不断重复同样的工作，例如使用卷积神经网络进行带宽预测，为视频自适应比特率设计一个 RNN，或为集群任务调度训练一个多层感知机。整个过程不仅需要针对不同的数据模态重新设计输入表示，还需进行参数调优与实验验证，以确保模型在真实网络复杂动态环境下的稳定表现。不过，这类模型普遍泛化能力有限，一旦网络条件、视频内容或任务结构出现分布漂移，模型性能便可能发生不可预测的下降，甚至退化至不如传统启发式算法的水平。

与此同时，大语言模型在跨模态、跨任务场景下展现出的优秀性能，为网络研究提供了新的思路。如果一个模型能够同时理解自然语言、图像等多种模态，并具备一定程度的推理与规划能力，能否借助这一模型替代以往针对单一任务的专用深度神经网络，使其在视频流控制、集群调度、拥塞控制等场景中均具备良好的可迁移性，可以实现“一个模型解决所有任务，且具有更优性能和更强泛化能力”的目标？

[主要贡献]

论文的核心贡献在于提出了 NetLLM 框架，这是首个统一且高效地将 LLM 适配到各种网络任务中的框架。

在技术架构方面，研究者设计了一个高度集成的端到端适配框架，这个框架的创新性体现在其系统性地解决了 LLM 应用于网络场景时面临的三大核心挑战：


- 通过多模态编码器解决了网络输入数据（如时间序列、图数据）与 LLM 纯文本输入之间的巨大模态差距。
- 通过网络头解决了 LLM 基于 Token 的自回归生成所导致的效率低下和幻觉问题，确保了答案的有效性和快速响应。
- 通过 DD-LRNA 方案解决了 LLM 参数规模大，以及基于强化学习（RL）任务所需环境交互耗时带来的高昂适应成本。

经过测试，利用 NetLLM 框架优化后的 LLM，在视频流畅度优化、资源调度等多个网络任务上的表现，都明显优于目前最先进的专用算法，并且在面对新环境时表现出了更强的适应能力。

[解决思路与方案]


NetLLM 框架包含三个巧妙的设计，系统化地解决了技术难题：

- **Multimodal encoder:** 网络任务存在各式各样的模态数据，无法直接作为 LLM 的输入进行有效处理。为此，作者在 NetLLM 当中设计了 multimodal encoder 模块。该模块首先使用处理特定模态的特征提取器，从原始输入信息当中提取出有用特征，再借助可训练的线性层，将提取出的特征映射到 token 空间，使得 LLM 能够对输入信息进行有效处理。



- **Networking head:** LLM 基于 token 预测的答案生成机制容易引发幻觉效应，导致产生无效答案而降低可靠性。此外，由于 LLM 往往需要多轮预测才能产生一个答案，这也导致了过高的推理延迟。为解决这一挑战。作者设计了不同的 **networking head** 已取代了 LLM 原始的输出层。每个 **networking head** 本质上是一个与网络任务相关的轻量级线性映射器，允许 LLM 在单轮预测就能产生有效答案，从而确保了 LLM 在网络领域的可靠性，同时降低了推理延迟。
- **Data-driven low-rank networking adaptation (DD-LRNA):** 为实现 LLM 向网络领域的适配，需要对 LLM 进行微调，以获取相应的领域知识来解决网络任务。为了降低微调 LLM 所带来的高昂开销，作者设计了 DD-LRNA 机制，其基于离线强化学习（Offline RL）技术对 LLM 进行微调，减少了大量的训练时间，同时采用高效参数微调（PEFT）技术，将参数更新局限在一小部分可训练参数，从而进一步降低微调的开销。

为验证 NetLLM 的有效性，作者选取了三个与网络领域紧密相关的任务：视角预测 (VP)、码率自适应传输 (ABR) 与集群作业调度 (CJS)。作者以 Llama2-7B 为基座模型，基于 NetLLM 对 Llama2-7B 进行领域迁移，适配到上述三个网络任务，并与相应任务领域的 SOTA 方法进行性能对比。主要实验结果如下图所示。可以看到，NetLLM 在所有任务上的性能持续超越了所有的方法，在 VP、ABR、CJS 任务上带来的平均性能提升分别达到 10.1-36.6%、14.5-36.6%、6.8-41.3%。这些结果不仅表明 NetLLM 在 LLM 网络领域适配上的有效性，同时也展示了在 NetLLM 的支持下，LLM 确实可以作为基座模型高效地完成各种网络任务。



(a) Average performance with different random seeds

[不足之处]

尽管 NetLLM 取得了显著的进步，但基于论文内容和实验分析，其设计仍存

在以下不足：

1.通用性依赖于外部编码器，非真正的端到端学习：NetLLM 的多模态编码器依赖于重用或集成已有的、针对特定模态设计的特征编码器（如 1D-CNN、GNN）。虽然这最小化了开销，但当面对全新的、未被涵盖的网络数据模态时，研究者仍然需要手动设计或整合新的特征编码器。这使得框架的通用性存在一定的限制。

2.推理阶段的计算开销与部署限制：尽管 DD-LRNA 极大地降低了训练成本，但基于 LLM 的架构在推理（即实际部署运行）时仍面临巨大的计算和内存开销。对于对实时性要求高、资源受限（如网络边缘设备、客户端）的分布式网络任务而言，这种高开销可能会成为实际部署的瓶颈。

3.缺乏可解释性分析：LLM 的核心价值在于其预训练的通用知识和优异的性能。然而，论文尚未深入探究为什么 LLM 在网络任务中表现优异，以及其内部的决策机制。

[个人思考]

我个人认为，这篇论文的价值在于推动了网络算法设计理念的结构性变革，即将研究重心从为单个任务定制 DNN 转向用统一的 LLM 框架。作者首次探索了利用 LLM 解决不同的网络任务，减少网络算法设计的开销并进一步提高性能表现。通过三个典型的网络任务案例，展示了 NetLLM 在网络领域适配的有效性，并揭示了 LLM 在网络领域的巨大潜力。

然而，尽管 NetLLM 框架潜力巨大，要将这种理念推向实际应用，未来的研究必须解决以下几个关键挑战：

1.未来的目标是让 LLM 不再依赖外部工具，而是自己就能理解各种原始网络数据，让 LLM 直接处理原始数据序列，彻底实现端到端的通用学习。

2.解决部署成本高的关键在于模型压缩。可以采用知识蒸馏技术，通过训练好的大模型去得到一个更小、更快的模型。这样，就可以把高性能的模型装进资源有限的设备中，以适应边缘部署的低延迟和资源限制。

3.现在的训练依赖于离线数据，而网络环境是不断变化的，未来的模型需要具备实时学习和增量更新的能力，能够在运行过程中不断吸收新的经验，以适应不断变化的网络条件。

总体而言，NetLLM 为网络算法的设计提供了一个更具可持续性的新方向，未来的研究可进一步提升 LLM 在网络领域的知识迁移能力，并使用模型蒸馏技术，确保新框架的效益能够覆盖到整个异构的网络生态系统。